Untitled

January 22, 2018

Populating the interactive namespace from numpy and matplotlib

1 Los datos


```
In [112]: dataHz = np.loadtxt('Hz_all.dat') #We read the data. They are in the archive Hz_all.da
In [113]: '''We save our different data in new variables.
          z \longrightarrow Redshift
          observations ---> Our observations
          errors ---> The errors of our observations
          111
         z = dataHz[:,0]
          observations = dataHz[:,1]
          errors = dataHz[:,2]
In [114]: figsize = (8, 6)
                                                  # definimos el tamaño de nuestra figura
         dpi = 300
                                                   # dots per inch
         rcParams['font.size'] = 10
                                               # establecemos el tamaño de la fuente
          rcParams['lines.linewidth'] = 1
                                                 # el grosor de las líneas
         rcParams['mathtext.fontset'] = 'cm'
                                                  # y el tipo de fuente en LaTex
          fig1 = figure(figsize=figsize, dpi=dpi) # definimos la figura
         plt.errorbar(z, observations, errors, #plt.errorbar(x, y, error_y)
                       xerr=None,
                       color='red', marker='o', ls='None',
                       elinewidth =1, capsize=3, capthick = 1,
```

```
label='$Datos$')
```

```
plt.legend(loc='best', frameon=False) #pon la legenda donde mejor quede sin marco
xlabel(r'$z$')
ylabel(r'$H(z) [km/s Mpc^{-1}]$')
```

 $\#savefig('data_plot.pdf', bbox_inches='tight') \ \#guardar \ la \ salida \ como \ un \ archivo \ pdf,$

Out[114]: <matplotlib.text.Text at 0x140b6f90>



2 Definimos el problema y el modelo teórico

Consideremos la extensión más simple del modelo de LCDM (materia oscura fría con constante cosmológica Λ). Consideraremos que Λ no es una constante, pero sigue una ecuación de estado de la forma $p=\omega\rho$ con $\omega\equiv Cte$.

Si consideramos un universo plano, se cumple que $\Omega_m + \Omega_{DE} = 1 \Rightarrow \Omega_{DE} = 1 - \Omega_m$

Digamos que utilizamos las "standar candles" (SNIa) como observaciones para medir a que velocidad se expande el universo para cierta etapa de la historia del cosmos.

De cosmología sabemos que el parámetro de Hubble evoluciona en función del Redshift y el contenido de la materia como


```
2.0.1 H(z) = H_0 \sqrt{\Omega_m (1+z)^3 + \Omega_{\Lambda}}
```

donde H_0 es el valor del parámetro de Huble en nuestra época. Los parámetros que vamos a estimar serán el valor de H_0 , ω y Ω_m .

3 Hacemos la inferencia de parámetros

Vamos a considerar un Likelihood Gaussiano, i.e. $L(\vec{\theta}) = \exp\left[-\frac{1}{2}\sum_{i}^{No.Obs}\frac{(H(z_i)_{obs}-H(z_i,w=-1,H_0,\Omega_m))^2}{\sigma_i^2}\right]$ #### donde $\vec{\theta}=\{H_0,M\}$. ##### Vamos a suponer que no tenemos información de los parámetros, salvo sus cotas límite. Digamos que $\Omega_m \in [0.1,1]$ y $H_0 \in [10,100]$. Por la ignorancia de nuestros parámetros, un buen prior que podemos considerar para estos es tomar un prior uniforme ##### $\Omega_m \sim U[0.1,1]$ ##### $H_0 \sim U[10,100]$

```
with model:
               start = pm.find_MAP()
               step = pm.Metropolis()
               db = SQLite('trace.db')
               trace = pm.sample(niter, trace=db, step=step, start=start,njobs=5, random_seed=123
In [118]: start
Out[118]: {'H0': array(68.21080972),
            'HO_interval__': array(0.60494477),
            'OmegaM': array(0.31849471),
            'OmegaM_interval__': array(-1.13754222)}
In [119]: with model:
               tracee = pm.backends.sqlite.load('trace.db')
               pm.traceplot(tracee, varnames=['OmegaM','HO'])
                         OmegaM
                                                                  OmegaM
                                               0.6
      Frequency A
                                               9.0.4
                                               B 0.2
                                                          50000
                                                                100000
                                            0.8
                                                                       150000
                                                                                    250000
                                                                             200000
                                                                    H0
      0.10
                                               Sample value
00 08
     0.10
0.05
      0.00
                                                          50000
                                                                100000
                                                                       150000
                                                                             200000
                                                                                    250000
In [139]: t = trace[niter//2:]
           t['OmegaM'].shape
           t['H0'].shape
Out[139]: (1075000,)
In [121]: OmegaM = trace.get_values('OmegaM', burn=niter//2, combine=True, chains=[0,2])
           OmegaM.shape
           H0 = trace.get_values('H0', burn=niter//2, combine=True, chains=[0,2])
           HO.shape
Out[121]: (430000,)
In [122]: pm.autocorrplot(t, varnames=['OmegaM','HO'])
           pass
```



```
In [123]: pm.effective_n(t)
Out[123]: {'H0': 34391.0, 'OmegaM': 7537.0}
In [124]: pm.gelman_rubin(t)
Out[124]: {'H0': 1.0004853292008946, 'OmegaM': 1.0000401305986388}
In [125]: plt.plot(pm.geweke(t['OmegaM'])[:,1], 'o')
          plt.axhline(1, c='red')
          plt.axhline(-1, c='red')
          plt.gca().margins(0.05)
          pass
          1.00
          0.75
          0.50
          0.25
          0.00
        -0.25
        -0.50
        -0.75
        -1.00
                                      7.5
```

10.0

12.5


15.0

17.5

2.5


0.0

5.0



In [127]: pm.summary(t, varnames=['OmegaM','HO'])

Out[127]: sd mc_error hpd_2.5 hpd_97.5 Rhat mean n_eff 0.001001 0.317201 0.072718 0.164740 0.469017 7537.0 1.000040 OmegaM НО 4.201709 59.541644 67.691635 0.025852 76.058639 34391.0 1.000485




 $/home/enriques/Downloads/yes/lib/python 2.7/site-packages/ipykernel/__main__.py: 2: \ Deprecation Warrend States and States are also become a supplied to the package of the packages of the packages of the packages and the packages of th$

- .ix is deprecated. Please use
- .loc for label based indexing or
- .iloc for positional indexing

See the documentation here:

http://pandas.pydata.org/pandas-docs/stable/indexing.html#ix-indexer-is-deprecated from ipykernel import kernelapp as app

/home/enriques/Downloads/yes/lib/python2.7/site-packages/ipykernel/__main__.py:2: FutureWarning: from ipykernel import kernelapp as app



```
import scipy.stats
gkde = scipy.stats.gaussian_kde([OmegaM, H0])
x,y = mgrid[0.:1.:.005, 10.:100.:.5]
z = array(gkde.evaluate([x.flatten(),y.flatten()])).reshape(x.shape)
contourf(x, y, z,3, linewidths=1, alpha=.5, cmap='Greys')
plt.colorbar();

ylabel(r'$H0$', fontsize=18, rotation=0)
xlabel(r'$\Omega_m$', fontsize=18)
legend()
axis([0.2, 0.6, 60., 80.])
savefig('param_dist.png')
```

